

1. 연구 제목

딥러닝 통계적 차익거래의 한국 주식시장 재현과 확장

Deep Learning Statistical Arbitrage in the Korean Stock Market: Replication and Extension

2. 연구 동기

실무와의 연관성

현재 운용사에서 국내주식형 인핸스드 인덱스 펀드 전략을 리서치하고 있습니다. 인핸스드 인덱스 펀드는 벤치마크를 기본으로 보유하면서 일부 종목의 비중을 벤치마크보다 늘리거나 줄여 초과수익을 추구합니다. 그런데 이렇게 늘린 비중(overweight)과 줄인 비중(underweight)만 떼어 놓고 보면, 늘린 만큼 사고 줄인 만큼 판 것이므로 합이 0인 롱숏 포트폴리오와 본질적으로 다르지 않습니다. 즉 인핸스드 인덱스의 초과수익은 벤치마크 위에 얹은 롱숏 포트폴리오에서 나옵니다.

이 롱숏 포트폴리오는 벤치마크 노출은 이미 중립이지만, 규모·가치·모멘텀 같은 팩터에는 의도치 않게 노출될 수 있습니다. 그러면 초과수익의 상당 부분이 종목 선택이 아니라 팩터 베타에서 나오고, 추적오차도 불필요하게 커집니다 (Clarke et al., 2002; Grinold & Kahn, 2000). 따라서 시장 중립을 넘어 팩터에도 중립인 롱숏 알파가 필요합니다. 이 논문의 잔차 포트폴리오가 바로 그런 포트폴리오로, 팩터 노출이 0이면서도 실제로 거래할 수 있습니다 (Guijarro-Ordóñez et al., 2025).

예측 가능성과 수익 가능성의 차이

팩터모형의 잔차는 평균적으로 거의 0입니다. 원 논문에서도 잔차 포트폴리오를 단순히 보유하기만 하면 연 1%도 벌지 못합니다. 이것만 보면 팩터가 수익률을 대부분 설명하며 시장은 효율적이라고 결론 내리기 쉽습니다. 그러나 같은 잔차라도 시계열 패턴에 따라 사고팔면 평균수익이 최대 50배까지 커집니다. 잔차에 담긴 정보는 평균이 아니라 움직임의 형태에 있으며, 수익률을 예측하기 어렵다는 것이 곧 수익을 낼 수 없다는 뜻은 아니라는 것이 이 논문의 핵심 주장입니다.

한국 시장 적용의 의의

- **무거운 거래 제약.** 한국은 2020년 3월~2021년 5월과 2023년 11월~2025년 3월에 공매도가 전면 금지되었고, 주식을 매도할 때마다 증권거래세가 부과됩니다. 원 논문은 거래비용 5bp와 공매도 비용 1bp만 가정했으므로, 비용과 제약이 실제로 큰 시장에서도 전략이 유효한지 검증할 수 있습니다.
- **적은 종목 수.** 원 논문과 같은 기준으로 표본을 구성하면 미국은 약 550종목이지만 한국은 하루 130~190종목에 그칩니다. 이 방법론은 여러 종목의 잔차를 모아 하나의 모형을 학습하므로, 학습 표본이 작은 시장에서도 작동하는지 확인할 필요가 있습니다.
- **선행 연구의 부재.** 2025~2026년 KAIST MFE 학위논문과 KOASAS 공개 목록에서 이 논문을 한국 시장에 적용한 연구는 찾지 못했습니다.

3. 핵심 논문

Guijarro-Ordóñez, J., M. Pelger, and G. Zanolli (2025). "Deep Learning Statistical Arbitrage." *Management Science*. doi:10.1287/mnsc.2022.03132

논문 개요

이 논문은 통계적 차익거래를 세 단계로 나누고, 나머지 조건을 고정한 채 단계별로 기존 방법과 딥러닝을 바꿔 가며 비교합니다.

단계	질문	기존 방법	이 논문
① 포트폴리오	무엇과 무엇을 짝지을까?	실제 종목 두 개를 짝지음 (Gatev et al., 2006)	종목과, 팩터로 합성한 짝 (mimicking portfolio)
② 신호	언제 사고팔까?	OU 평균회귀, Fourier 파형 등 함수 형태를 미리 정함 (Yeo & Papanicolaou, 2017)	CNN+Transformer(Vaswani et al., 2017)가 패턴을 데이터에서 직접 학습
③ 배분	얼마나 사고팔까?	괴리가 일정 수준을 넘으면 진입하는 임계값 규칙	비용과 제약을 포함해 Sharpe ratio를 직접 최대화

핵심 아이디어

- **거래 가능한 포트폴리오로서의 잔차.** 잔차는 $\varepsilon_t = (I - \beta_{t-1} W_{F,t-1}^\top) R_t = \Phi_{t-1} R_t$ 로 쓸 수 있고, Φ 의 각 행은 종목별 비중입니다. 따라서 잔차는 회귀식의 오차항이 아니라, 한 종목을 사고 팩터로 합성한 짝을 파는 팩터 중립 롱숏 포트폴리오입니다. 짝이 될 종목이 따로 없어도 팩터를 이용해 합성할 수 있습니다.
- **전 종목 공통 모형.** 원 수익률은 소수의 팩터에 크게 좌우되어 종목들이 함께 움직입니다. 팩터를 제거하면 종목 간 상관이 약해지고 성격도 비슷해지므로, 수백 종목과 수천 거래일을 하나의 학습 표본으로 묶을 수 있습니다. 덕분에 30일 길이의 짧은 시계열로도 딥러닝 모형을 학습할 수 있습니다.
- **Sharpe ratio 직접 최적화.** 예측오차(MSE)를 줄이는 대신 Sharpe ratio를 목적함수로 삼아 신호와 배분을 동시에 학습합니다. 거래비용과 공매도 비용도 학습 단계에서 목적함수에 반영합니다.

원 논문의 주요 결과

미국 약 550종목, 표본외 기간 2002~2016년, 거래비용 반영 전 연율 Sharpe ratio 기준입니다.

비교	결과
신호 추출 방법 (PCA 5팩터 잔차)	OU+Threshold 0.73 → Fourier+FFN 1.98 → CNN+Transformer 3.36
잔차 종류 (CNN+Transformer, 5팩터)	잔차화 없음 1.64 FF5 3.21 PCA5 3.36 IPCA5 4.16
거래비용 반영 (IPCA, 5bp / 1bp)	약 1.0~1.2로 하락하지만 양(+)의 값 유지

저자들은 성과를 좌우하는 것이 ② 신호 추출이며, 팩터모형은 충분히 풍부하기만 하면 종류에 따른 차이가 크지 않다고 결론짓습니다.

선정 이유

① 앞서 설명한 실무 문제와 직접 연결됩니다. ② Management Science에 게재된 논문입니다(2019년 첫 초고, 2025년 게재). ③ 새로운 방법론을 제안하기보다 기존 도구를 결합한 실증 연구여서 재현과 확장에 적합합니다. ④ 저자들이 코드를 공개해 세부 사양을 추측하지 않고 대조할 수 있습니다. ⑤ 필요한 데이터가 일별 주가와 기업특성 위주여서 한국에서도 구할 수 있습니다.

진행 상황

한국 데이터로 세 단계를 모두 구현했으며, 원 논문의 표와 그림 45개를 한국 표본으로 생성하는 단계까지 진행했습니다. 다만 PCA 잔차 결과는 9월 2일 미팅 이후 발견된 오류를 수정해 다시 계산하고 있어, 이 계획서에는 해당 오류의 영향을 받지 않은 FF 잔차 결과만 인용합니다.

4. 연구 가설과 근거

H1~H3는 원 논문의 주장이 한국에서도 성립하는지 확인하는 재현 가설이고, H4~H5는 한국의 거래 제약과 실무 적용을 다루는 확장 가설입니다. Sharpe ratio의 차이는 Ledoit & Wolf (2008)의 방법으로 검정하고, 알파는 팩터 회귀로 확인합니다.

H1. 잔차화의 효과 재현

가설 개별주식 수익률보다 팩터를 제거한 잔차로 거래할 때 성과가 높다.

근거 원 수익률은 소수의 팩터에 좌우되어 종목들이 함께 움직입니다. 팩터를 제거해야 종목별로 독립적인 신호가 남고, 하나의 모형으로 전 종목을 학습할 수 있습니다.

예비 결과 CNN+Transformer의 Sharpe ratio는 잔차화하지 않으면 -0.08이지만, FF3 잔차에서는 2.83, FF5 잔차에서는 2.27입니다. 잔차화 없이도 1.64를 기록한 미국과 달리, 한국에서는 잔차화 없이는 전략이 성립하지 않습니다.

H2. 신호 추출 방법에 따른 성과 차이 재현

가설 같은 잔차에서도 성과는 $OU < Fourier < CNN+Transformer$ 순이며, 그 차이는 신호 추출 단계에서 발생한다.

근거 OU는 한 가지 속도의 평균회귀만, Fourier는 미리 정해 둔 사인·코사인 파형만 포착할 수 있습니다. 실제 잔차에는 추세와 반전이 섞여 있으며, CNN+Transformer는 이러한 형태를 데이터에서 직접 학습합니다.

예비 결과 FF5 잔차에서 $0.47 < 1.46 < 2.27$, FF3 잔차에서 $0.73 < 1.76 < 2.83$ 으로 미국과 같은 순서가 나타납니다.

H3. 팩터 프리미엄과의 구분 재현

가설 이 전략의 수익은 팩터 프리미엄으로 설명되지 않는다.

근거 잔차 포트폴리오는 구성 단계부터 팩터 노출이 0입니다. 따라서 수익은 위험을 부담한 대가가 아니라, 일시적인 가격 괴리가 해소되면서 발생한 것이어야 합니다.

예비 결과 FF5 잔차 전략의 수익률을 한국 6팩터(FF5 + 모멘텀)에 회귀하면 알파는 연 7.6%($t = 3.59$), R^2 는 1.1%입니다.

H4. 거래비용과 공매도 제약의 영향 확장

가설 거래비용과 공매도 제약을 반영하더라도, 비용을 학습 단계에서 고려한 모형은 알파를 유지한다.

근거 이 전략은 매일 포트폴리오의 대부분을 교체합니다. 미국에서도 5bp의 비용만 반영하면 Sharpe ratio가 4.16에서 1.11로 떨어지는데, 한국은 매도할 때마다 증권거래세가 부과되어 비용 부담이 이보다 몇 배 큼니다. 반면 비용을 목적함수에 포함하면 모형이 스스로 거래를 줄이는 방향으로 학습합니다.

검증 방법 한국의 실제 거래비용으로 다시 학습하고, 공매도 금지 기간과 허용 기간의 성과를 비교합니다.

H5. 인핸스드 인덱스 적용 가능성 확장

가설 회전을 제약을 학습에 반영하면, 잔차 포트폴리오를 인핸스드 인덱스의 알파 원천으로 활용할 수 있다.

근거 인핸스드 인덱스의 over/underweight는 곧 롱숏 포트폴리오이므로, 그 자리에 잔차 포트폴리오를 넣을 수 있습니다. 잔차 포트폴리오는 팩터 노출이 0이어서 의도치 않은 팩터 베팅도 생기지 않습니다. 남은 걸림돌은 벤치마크 비중 이상으로는 줄일 수 없다는 공매도 제약과 회전율입니다.

예비 결과 FF 잔차 전략 8개를 KOSPI 200 펀드 구조에 그대로 적용해 본 결과, 베팅은 거의 0으로 맞출 수 있었고 추적오차도 절반 수준으로 줄었습니다. 그러나 거래비용(연 2.4~5.6%)이 비용 차감 전 초과수익(최대 +0.4%)보다 커서 8개 전략 모두 순초과수익이 음수였습니다. 결국 걸림돌은 회전율이며, 회전율과 추적오차 제약을 목적함수에 넣어 다시 학습하는 것이 확장 연구의 핵심입니다.

5. 데이터

표본 구성

원 논문과 같은 기준(전월 말 시가총액이 전체 시장의 0.01% 초과)으로 KOSPI·KOSDAQ 보통주를 선정합니다.

데이터	출처	확보 현황
일별 주가·수익률·시가총액·거래대금	FnGuide	2015.1~2026.7, 4,962종목 확보
재무제표 및 기업특성 46개	FnGuide (공시일은 DART)	FY2016부터 확보, 과거 추가 필요
현금배당, 상장폐지 수익률	FnGuide, KRX	추가 확보 필요
무위험수익률 (CD 91일물)	한국은행 ECOS	확보
팩터 (시장·규모·가치·수익성·투자·모멘텀)	직접 구축	구축 완료
KOSPI 200 구성종목 및 비중	FnGuide	확보
공매도 가능 여부, 대차, 금지 기간, 거래세	KRX, 예탁결제원, 금융위	확장 단계에서 확보

남은 과제

- **짧은 표본 기간.** 현재 표본외 기간은 2.5년(2024.1~2026.7)으로, 15년인 원 논문과 달리 하나의 시장 국면만 포함합니다. 자료를 2000년대 초까지 확장해 표본외 기간을 10년 이상으로 늘릴 계획입니다.
- **배당 미반영 수익률.** 현재 수익률은 현금배당을 제외한 수정주가 수익률입니다. 원 논문과 정의를 맞추려면 배당을 포함한 총수익률로 바꿔야 합니다.
- **IPCA 추정 이력 부족.** IPCA(Kelly et al., 2019)는 기업특성으로 팩터를 추정하며 240개월의 이력이 필요하지만, 현재 기업특성 자료는 139개월입니다. 재무 자료를 과거로 확장하고, 그래도 부족하면 짧은 기간으로 추정했음을 명시해 보고합니다.

6. 참고문헌

- Clarke, R., de Silva, H., & Thorley, S. (2002). Portfolio Constraints and the Fundamental Law of Active Management. *Financial Analysts Journal*, 58(5), 48–66.
- Gatev, E., Goetzmann, W. N., & Rouwenhorst, K. G. (2006). Pairs Trading: Performance of a Relative-Value Arbitrage Rule. *Review of Financial Studies*, 19(3), 797–827.
- Grinold, R. C., & Kahn, R. N. (2000). The Efficiency Gains of Long-Short Investing. *Financial Analysts Journal*, 56(6), 40–53.
- Guijarro-Ordóñez, J., Pelger, M., & Zanolli, G. (2025). Deep Learning Statistical Arbitrage. *Management Science*. <https://doi.org/10.1287/mnsc.2022.03132>
- Kelly, B. T., Pruitt, S., & Su, Y. (2019). Characteristics Are Covariances: A Unified Model of Risk and Return. *Journal of Financial Economics*, 134(3), 501–524.
- Ledoit, O., & Wolf, M. (2008). Robust Performance Hypothesis Testing with the Sharpe Ratio. *Journal of Empirical Finance*, 15(5), 850–859.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30.
- Yeo, J., & Papanicolaou, G. (2017). Risk Control of Mean-Reversion Time in Statistical Arbitrage. *Risk and Decision Analysis*, 6, 263–290.